

Opake Prädikate gegen symbolische Ausführung mittels stochastischer Unentscheidbarkeit

Teilnehmende: Paul Baumgartner (18 J.)
Erarbeitungsort: Hildesheim
Projektbetreuende: Dr. Arndt Latußeck
Fachgebiet: Mathematik/Informatik
Wettbewerbssparte: Jugend forscht
Bundesland: Niedersachsen
Wettbewerbsjahr: 2026

Inhaltsverzeichnis

1 Projektüberblick	0
2 Einleitung	1
3 Theoretische Grundlagen	1
3.1 Obfuscation	1
3.2 Opaque Prädikate	1
3.3 Symbolische Ausführung	2
3.4 Kumulative Verteilungsfunktionen	3
4 Hintergrund und Motivation	3
5 Ansatz	5
5.1 Angreifermodell	5
5.2 Stochastische opaque Prädikate	6
5.3 Theoretische Sicherheit	7
5.4 Algorithmus	7
6 Implementierung	8
6.1 Entscheidungen	8
6.2 Generierung von Pseudozufallsvariablen	9
6.3 Wahrscheinlichkeitsverteilungsgenerierung	9
6.4 Generierung von ununterscheidbarem Füllcode	10
7 Evaluierung	10
7.1 Kriterien	10
7.2 Vergleich mit existierenden Obfuscationsmethoden	10
8 Ergebnisdiskussion	10
9 Fazit und Ausblick	10
Literaturverzeichnis	A
Abbildungsverzeichnis	B

1 Projektüberblick

Dieses Projekt behandelt Softwareobfuscation, also das Verschleiern/Verstecken wichtiger Funktionalitäten von Programmen. Konkret wird eine neue Art der Obfuscation vorgestellt, welche sich als resistent gegenüber existierender Methoden zur Deobfuscation erweist. Hierfür werden Wahrscheinlichkeiten in Bedingungen innerhalb des Programmes verknüpft, wobei für einen Angreifer, welcher das Programm verstehen möchte, unklar ist, inwiefern diese Bedingungen wahr oder falsch sind. Obwohl die Erfüllung dieser Bedingungen zufällig ist, werden Wahrscheinlichkeiten verwendet, welche in der Praxis garantieren, dass immer das gewünschte Verhalten auftritt.

2 Einleitung

Obfuscation (lat. *obfuscare*: verdunkeln) bezeichnet jede Transformation von Programmen zur Hinderung von sog. Reverse Engineering - der Analyse von Software zum Cracken, Verstehen oder Kopieren. Obfuscation kommt zum Einsatz in der Malwareentwicklung - um vor Detektion von sog. *EDRs* zu schützen, in der Industrie - um vor Kopien von Softwarefunktionen sowie vor Cracking zu schützen und im Militär - um dem Feind ein Verständnis der eigenen Waffensysteme zu behindern. Da das Programm hierbei noch die Ursprüngliche Semantik beibehält kann jede Software mit genügend Zeit, Aufwand und Geld trotz Obfuscation verstanden werden. Der Sinn von Obfuscation ist also nicht die komplette Verhinderung von *Reverse Engineering*, sondern vielmehr dieses wirtschaftlich unrentabel zu machen.

Diese Arbeit fokussiert sich auf eine Art der Obfuscation, der Kontrollflussofuscation, und der meist verbreiteten Angriffsweise, um diese zu bekämpfen. ...

Diese Arbeit nimmt ein mathematisch-informatisches Grundwissen an Assembler, Kompilern sowie grundlegender Zahlentheorie an. Zudem wird die Iverson-Klammer/Prädikatabbildung $[\cdot]$ verwendet mit $[P] = 1$, falls die Aussage P wahr ist und $[P] = 0$ sonst. Vergleicht eine Aussage zwei Variablen, so wird hierfür „ $=$ “ verwendet.

3 Theoretische Grundlagen

3.1 Obfuscation

Collberg et al. [4] definieren Obfuscation wie folgt:

Definition 3.1 (Obfuscation). Sei $P \xrightarrow{\mathcal{T}} P'$ eine Transformation eines *Quellprogrammes* P zu einem *Zielprogramm* P' . Eine solche Transformation ist eine Obfuscation, wenn das obfuskierte Programm P' dasselbe beobachtbare Verhalten wie P für den Endnutzer aufweist.

Eine Obfuscation hat immer das Ziel, die Komplexität eines Programmes so zu erhöhen, dass dessen interne Logik für einen Angreifer nur schwer verständlich ist. Für die Komplexität von Programmen gibt es mehrere Metriken [5].

Per Definition sind Nebenwirkungen (z.B. Herunterladen von neuen Daten etc.) erlaubt, solange sie nicht vom Nutzer erfahren werden. Die präsentierte Methode dieser Publikation nutzt diese Lockerung der Einschränkungen auf obfuscierende Transformationen aus, wie später ersichtlich sein wird.

Um eine Obfuscationsmethode zu evaluieren werden typischerweise die Metriken *Stärke*, *Resilienz*, *Kosten* und *Tarnung* verwendet [4].

3.2 Opake Prädikate

Die folgenden Definitionen sind aus [10] sowie vom Pionierwerk [5] modifiziert übernommen. Es wird sich auf hierbei auf invariante opake Prädikate beschränkt. Ferner wird angenommen, dass alle Funktionen/Prädikatenterme evaluierbar sind.

Definition 3.2 (Opake Prädikate). Sei $O : \Phi \rightarrow \{0, 1\}$ eine Abbildung einer Variable $\phi \in \Phi$ zu einem Prädikat. Das Prädikat $O(\phi)$ ist opak, wenn für alle $\phi \in \Phi$ gilt, dass $O(\phi)$ denselben Wert (1 oder 0 bzw. wahr oder falsch) hat.

In anderen Worten: Das Prädikat $O(\phi)$ ist opak, wenn dessen Wert für alle möglichen Parameter *a priori* bestimmt ist (also für den Programmierer bekannt ist) aber für ein Verständnis einer weiteren Person (ein Angreifer) *a posteriori* (durch Beobachtung) zu bestimmen ist [5].

Diese Arbeit unterscheidet zwischen zwei Arten opaker Prädikate:

Definition 3.3. Sei $O : \Phi \rightarrow \{0, 1\}$ ein opakes Prädikat.

$O(\phi)$ ist vom Typ

1. P^T , wenn für alle $\phi \in \Phi$ gilt: $O(\phi) = 1$ bzw. *wahr*.
2. P^F , wenn für alle $\phi \in \Phi$ gilt: $O(\phi) = 0$ bzw. *falsch*.



Abbildung 1: Kontrollflussgraph einer einfachen Funktion mit opakem Prädikat. Abbildung einer Funktion mit vielen opaken Prädikaten. Abbau aus der Disassembly des Spiels *Overwatch* mittels IDA entnommen.

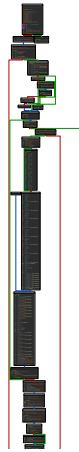


Abbildung 2: Ausschnitt des Kontrollflussgraphen aus der Disassembly des Spiels *Overwatch* mittels IDA entnommen.

Opake Prädikate werden in der Softwareobfuscation eingesetzt, um ein Verständnis über den Kontrollfluss des Programms zu behindern [5, 10]. Damit opake Prädikate als Obfuscationsmethode¹ genutzt werden können, müssen sie wiederholt angewandt werden. Dadurch entsteht ein komplexerer Kontrollflussgraph und der Angreifer weiß folglich nicht, welche Basisblöcke zu analysieren sind. Die Stärke der opaken Prädikate ist hierbei abhängig von der Stärke ihres Terms/Ausdrucks [5]. Mit zunehmender Komplexität der Prädikate und zunehmender Anzahl dieser, nimmt also auch die Obfuscationsstärke (Verwirrung und Unverständnis) beim Angreifer zu.

Beispiel 1. Das Prädikat $O(\phi) = [-1977224191 \& 1 == 1]$ aus Abb. 1, wobei „ $\&$ “ dem bitweisen „und“ Operator entspricht, ist sehr einfach. Eine Berechnung genügt, um zu erkennen, dass das Prädikat immer wahr ist.

Beispiel 2. Das Prädikat $O(\phi) = [(y < 10) \vee (x \cdot (x + 1) \bmod 2 \equiv 0)]$ aus [6] mit $\phi = (x, y)$ und $x, y \in \mathbb{Z}$ ist etwas komplexer. Auch dieses Prädikat ist immer wahr, da $x \cdot (x + 1)$ immer gerade ist. Der Wert ist folglich von y unabhängig.

3.3 Symbolische Ausführung

Im Gegensatz zur konkreten Ausführung, welche ein Programm für spezifische Inputs ausführt, ermöglicht die symbolische Ausführung die Analyse des Programmverhaltens für ganze Klassen an Inputs [1]. Die

¹D.h. dass der wirkliche Pfad, welcher von einem opaken Prädikat verschleiert wird, nicht einfach erkannt werden kann

Notwendigkeit symbolischer Ausführung ergibt sich schon am Beispiel einer Funktion mit zwei 64-Bit Variablen. Um mit konkreter Ausführung herauszufinden, für welche Werte eine Bedingung wahr ist, müsste man hier $2^{64} \cdot 2^{64} = 2^{128}$ verschiedene Werte ausprobieren. Ein solcher Bruteforce ist selbst für die modernsten Computer unmöglich - symbolische Ausführung hingegen schon. Ein symbolischer *Ausführungsengine* besteht aus 2 Hauptkomponenten: einem *symbolischen Ausführungsmodul* und einem SMT-Solver zur Lösung/zum Prüfen von Bedingungen/Einschränkungen. Es gibt zwei Arten symbolischer Ausführungsengines: statisch und dynamisch (*concolic execution*) [11]. Bei der statischen symbolischen Ausführung wird für jeden Kontrollflussweg eine *Pfadformel* und ein *symbolischer Speicher* mitgeführt [1].

1. Die Pfadformel, eine boolesche Formel erster Ordnung, führt die Bedingungen der entlang des Pfades genommenen Verzweigungen zusammen [1].
2. Der symbolische Speicher bildet unbekannte Variablen (z.B. Parameter und alle darauf aufbauende Variablen) auf symbolische Ausdrücke ab [1].

Hierdurch können schließlich über den SMT-Solver allgemeine Aussagen über die Erreichbarkeit bestimmter Pfade oder Variablenwerte getroffen werden [1]. Ist eine Pfadformel erfüllbar, kann der Solver zudem konkrete Eingewerte hierfür liefern [1]. Hat das Programm aber besonders viele Verzweigungen (z.B. durch Schleifen) oder komplexe Constraints (z.B. nichtlineare Arithmetik), stoßen die SMT-Solver an ihre laufzeittechnischen Grenzen [1].

Um (u.a.) dies zu lösen wurden dynamische Ausführungsengines als Erweiterung entwickelt. Das *symbolische Ausführungsmodul* verwaltet einen symbolischen und konkreten Zustand. Das Programm wird dafür mit konkreten Inputs ausgeführt [1]. Parallel speichert der konkrete Zustand Laufzeitwerte und durchlaufene Verzweigungen [1]. Der symbolische Zustand fungiert wie oben beschrieben, nur dass Pfadformel und symbolischer Speicher auf einen Pfad beschränkt sind [1]. Nach Abschluss eines Pfades werden die in der Pfadformel enthaltenen Bedingungen einzeln negiert und an den SMT-Solver übergeben, um konkrete Eingaben zu berechnen, die einen bisher ungetesteten Pfad aktivieren [1]. Der Vorgang wiederholt sich [1].

Symbolische Ausführung ist ein populärer Ansatz für die Bekämpfung opaker Prädikate [11].

3.4 Kumulative Verteilungsfunktionen

Definition 3.4 (Kumulative Verteilungsfunktion). Eine Funktion F ist eine kumulative Verteilungsfunktion, wenn gilt:

- (1) F ist streng monoton steigend: **TODO**
- (2) F ist rechtsstetig: **TODO**
- (3) $\lim_{x \rightarrow -\infty} F(x) = 0$ und $\lim_{x \rightarrow +\infty} F(x) = 1$

4 Hintergrund und Motivation

Hier objektiver werden, evtl. "Literature Reviews" zitieren und zusammenfassen Dieser Abschnitt präsentiert den aktuellen Stand der Forschung zu opaken Prädikaten und begründet daraus diese Arbeit.

```

1 int func(int symvar){
2     int j = symvar;
3     if(j == 7){
4         Foo();
5     }
6 }
```

(a) Ursprüngliches Programm, übernommen aus [11].

```

1 int func(int symvar){
2     int j = symvar;
3     int 11_ary[] =
4         {1,2,3,4,5,6,7};
5     int 12_ary[] = {j
6         ,1,2,3,4,5,6,7};
7     int i = 12_ary[11_ary[j
8         %7]];
9     if(i == j)
10        Bogus();
11 }
```

(b) Bi-Opakes Prädikat (symbolischer Arbeitsspeicher) [11].

```

1 int func(int symvar){
2     int j = symvar;
3     float f = j/1000000.0;
4     if(f==0.1){
5         Bogus();
6     }
7     if((1024+f == 1024 && f>0
8         && j==7)){
9         Foo();
10    }
11 }
```

(c) Floating-point number.

```

1 ...
2
```

```

1 ...
2
```

(d) Covert symbolic propagation.

(e) Parallel programming.

Abbildung 3: Opaque predicate examples attacking the challenges of symbolic execution.

Da seit der Formalisierung opaker Prädikate [4] eine Vielzahl unterschiedlicher Varianten opaker Prädikate veröffentlicht wurden, erhebt dieser Abschnitt keinen Anspruch auf Vollständigkeit. Stattdessen werden aktuelle, zentrale Ansätze exemplarisch vorgestellt, um Forschungsstand und Herausforderungen zu verdeutlichen.

Existierende Literatur beschränkt sich vornehmlich auf statische Analyseansätze. Dynamische Analyseideen z.B. zur probabilistischen Untersuchung opaker Prädikate wurden veröffentlicht und experimentell untersucht, ergaben aber eine zu hohe Fehlerquote. Insbesondere reduzieren sich publizierte Ansätze auf symbolische Ausführung. Dies hat den Hintergrund, dass die symbolische Ausführung momentan eine der effektivsten automatisierten Analysemethoden bildet, welche mit wenig Aufwand und eigenem Eingriff verwendet werden kann. Andere Analysemethoden, wie z.B. *Tainting* sind zudem abhängiger von Faktoren neben den opaken Prädikaten selbst. Im Falle des *Taintings* ist die Qualität des Füllcodes wesentlich.

Trotz der „Effektivität“ existierender Methoden, bleiben viele theoretisch-formell unbegründet. Ihre Resistenz basiert auf Implementierungsschwächen² existierender symbolischer Ausführungsengines und nicht ihren fundamentalen Grenzen (bzw. den der SMT-Solver) [11]. Als Beispiel hierfür dienen die Bi-Opaken Prädikate [11]. Eine Befragung von Audrey Dutcher, einer der Entwicklerinnen von *Angr* [9] ergab: drei der vier in [11] dargestellten Methoden können nun von *Angr* problemlos symbolisch ausgeführt werden³. Die Deobfuscation weiterer Methoden wie [**linBranchObfuscationUsing2013**] und [3] liegt also alleine in der Verbesserung existierender symbolischer Ausführungsengines. Eine

²bzw. Heuristikschwächen.

³(a) symbolischer RAM: Ausführbar für Arrays mit einer Länge unter 257.

(b) Gleitkommazahlen: Ausführbar, wenn keine x86 long double Datentypen verwendet werden.

(c) Verdeckte symbolische Kontrollflussübertragung (*covert symbolic propagation*), in [11] über Dateisystem-Operationen implementiert: Ausführbar.

(d) Threads: Noch nicht implementiert.

Deobfuscation ist in gewisser Weise nur eine Frage der Zeit.

TODO: evtl. mit Lit. Review stützen

TODO: Tabelle evtl basierend auf Lit. Review?

TODO: Abbildung mit verschiedenen Varianten

TODO: Code obfuscation against symbolic execution attacks: „(1) path explosion, (2) path divergence and (3) complex constraints.“

TODO: mehr Obfuscationsmechanismen + Deobfuscatoren einbringen!!! => Zeigen, was ich alles recherchiert habe!

- Obfuscator-LLVM
- (Collberg et al.) Tigress (dynamic opaque predicates!!)
- Bi-Opaque Prädikate
- Linear Obfuscation to Combat Symbolic Execution
- „When Are Opaque Predicates Useful“
- „Software obfuscation on a theoretical basis and its implementation,“

Begründung für meinen Ansatz:

- Schnell
- Resistent gegenüber Pattern-Matching

5 Ansatz

5.1 Angreifermodell

Diese Arbeit geht aufgrund der Ähnlichkeit behandelter Thematik von einem Angreifermodell aufbauend auf [11] aus. Ein Angreifer hat direkten Zugriff auf das Programm und dessen Anweisungen. Es sei dem Angreifer hierbei nicht vorgegeben, wo und inwiefern das Programm obfuscated ist. Der Angreifer kann das Programm nur statisch analysieren. Der Angreifer kann das Programm nicht im vollen Ganzen dynamisch ausführen. Solchen Situationen begegnet man z.B. bei Malware, welche gegen Virtuelle Maschinen (*virtual machines*) gehärtet ist oder bei Software, welche für proprietäre und unverfügbar Systeme geschrieben ist.

Pattern matching, also das Suchen von Assembler-Anweisungsfolgen, kann hierbei zum Finden und Löschen zuvor erkannter opaker Prädikate verwendet werden.

Zudem kann der Angreifer Funktionen symbolisch ausführen. Über eine Anfrage an den SMT-Solver kann hierbei geprüft werden, ob ein Prädikat für alle Eingabewerte wahr ist. Ist dies der Fall, so handelt es sich um ein opakes Prädikat, welches gelöscht werden kann.

TODO: weitere Methoden aus "When are opaque predicates useful?" übernehmen

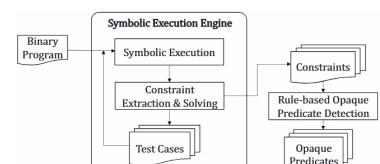


Abbildung 4: Konzeptuelles Framework zur Erkennung opaker Prädikate mit symbolischer Ausführung, Abb. aus [11] übernommen

TODO: selbst machen

Eine Härtung gegen weitere (dynamische) Analysemethoden des Angreifers wird in Abschnitt 9 diskutiert.

5.2 Stochastische opake Prädikate

Während andere Methoden wie [11] auf den praktischen Implementierungslimitationen symbolischer Ausführungsengines basieren, nutzt diese Methode deren fundamentale Grenzen aus.

TODO: Funktion von symbolischen Ausführungsengines Dies genügt für die Untersuchung deterministischer Algorithmen und entscheidbarer Probleme.

Will man allerdings Aussagen über einen probabilistischen Algorithmus treffen, so ist dies ohne erhebliche manuelle Eingriffe eines Nutzers in Form von extra Beschränkungen (*constraints*) unmöglich. Jede zufällige Variable eines jeden Schleifenaufrufes muss vom constraint solver als symbolische Variable betrachtet und somit für alle möglichen Werte überprüft werden. Bei einem Monte-Carlo-Algorithmus heißt dies allerdings, dass auch unwahrscheinliche Variablenwerte, welche zu falschen Ergebnissen führen, überprüft werden. Der Wahrheitsgehalt wird somit zwar formell logisch korrekt bewiesen - praktisch allerdings nicht.

Beispiel 3. Man betrachte einen Algorithmus, welcher mit einer Wahrscheinlichkeit von 99,999999999% den Wert 1 zurückgibt und mit einer Wahrscheinlichkeit von 0,000000001 den Wert 0 zurückgibt.

Algorithm 1 Beispiel eines probabilistischen Algorithmus

```

1: procedure Foo()
2:    $x \leftarrow \text{UNIFORMRAND}(0, 1)$ 
3:   if  $x \leq 0,9999999999$  then
4:     return 1
5:   end if
6:   return 0
7: end procedure
```

Nutzt man einen symbolischen Ausführungsengine, um zu prüfen, ob dieser Algorithmus den Wert 1 wiedergibt, so würde dieser behaupten, dass dies falsch sei.

Dies bildet die Grundidee stochastischer opaker Prädikate. Anstatt Prädikate zu bilden, welche für alle Werte ihrer Parameter *wahr* bzw. *falsch* sind, werden Prädikate erzeugt, deren gewünschter Wert so wahrscheinlich ist, dass das Gegenteil praktisch nie auftritt.

Definition 5.1 (Stochastische opake Prädikate). Sei $\mathcal{O} : \Phi \rightarrow \{0, 1\}$ eine Abbildung einer Variable $\phi \in \Phi$ zu einem Prädikat. Das Prädikat $\mathcal{O}(\phi)$ ist stochastisch opak, wenn der Fall $A \in \{0, 1\}$ mit einer so hohen Wahrscheinlichkeit eintritt, dass der Fall \overline{A} vernachlässigbar ist.

Definition 5.2 (Konstruktionsschema stochastisch opaker Prädikate). Sei X eine Zufallsvariable mit beliebiger Wahrscheinlichkeitsverteilung $P(X; \theta)$, wobei θ die Parameter der Verteilung darstellen. Das stochastisch opake Prädikat $\mathcal{O}(\phi)$ wird wie folgt konstruiert:

$$\mathcal{O}(\phi) = [f(X) \bowtie c],$$

wobei:

1. f eine Transformation durch arithmetische und bitweise Operationen ist (z. B. $f(X) = m \cdot (X \oplus k) + b$), mit Konstanten $(m, k, b) \in \mathbb{R}$,
2. \bowtie ein Zahlenvergleichsoperator ist ($=, >, <, \geq, \leq$) und
3. c eine festgelegte Konstante ist.

Definition 5.3. \mathcal{P}_{stoch} ist die Klasse aller stochastischen opaken Prädikate.

Beispiel 4. Das wahrscheinlich einfachste stochastische opake Prädikat ist $O(\phi) = [UNIFORM(0, 1) \leq 1 - 10^{-5}]$. Die Wahrscheinlichkeit, dass dieses Prädikat wahr ist, beträgt $10^{-5} = 0,001\%$.

Beispiel 5. $O(\phi) = [Pois(5) \geq 15]$. Die Wahrscheinlichkeit, dass dieses Prädikat unwahr ist beträgt $\sum_{k=15}^{\infty} \frac{5^k e^{-5}}{k!} = 1 - \sum_{k=0}^{14} \frac{5^k e^{-5}}{k!} \approx 0,023\%$

Um zu garantieren, dass das Programm, in welchem das stochastische opake Prädikat eingefügt wurde, weiterhin funktioniert, kann für den ungewünschten Gegenfall praktische eine Wahrscheinlichkeit eingesetzt werden, welche unter der eines Hardwarefehlers liegt. Auch gewöhnliche Programme bzw. Computer können spontan versagen. Durch das Nutzen so geringer Wahrscheinlichkeiten ...

5.3 Theoretische Sicherheit

Aus dem Angreifermodell und den Evaluierungskriterien von Collberg et al. [4, 5] ergibt sich, dass ein sicheres opakes Prädikat folgende Eigenschaften aufweisen muss:

1. Ununterscheidbarkeit des Füllcodes
2. Geringe Laufzeitkosten
3. Nichtablesbarkeit der Pfadwahrscheinlichkeiten
4. Resistenz gegenüber symbolischer Ausführung, ...TODO

TODO: erklären, warum alles zutrifft.

5.4 Algorithmus

Für jedes zu generierendes opakes Prädikat wird im Programm ein Pseudozufallsvariable x generiert. Verschiedene Methoden hierfür werden in Abschnitt 6.2 gegeben. Wichtig ist, dass der Angreifer den Wert von x nicht statisch bestimmen kann. Es wird angenommen, dass x gleichverteilt ist. Diese Verteilung wird nun in eine andere (z.B. Normal-, Exponential-, Bernoulliverteilung) transformiert. Über diese können nun wahrscheinliche bzw. unwahrscheinliche Aussagen getroffen werden. Abschnitt 5.4 zeigt die Umsetzung eines stochastischen opaken Prädikats in einem Programm.

Der Pseudocode für die Generierung solcher stochastischer opaker Prädikate ist in Algorithmus 3 beschreiben.

Algorithm 2 Beispiel eines stochastisch opaken Prädikats

Require: x : zufällige, unbekannte Zahl

```
1: SkalierteZufallszahl  $\leftarrow$  ABBILDUNG AUF EINHEITSINTERVALL( $x$ )           ▷ Einheitsintervall: [0; 1]
2: PoissonVerteilt  $\leftarrow$  INVERSECDF(SkalierteZufallszahl,  $\lambda = 5$ )
3: if PoissonVerteilt  $\leq 10$  then
4:   ...
5: else
6:   ...
7: end if
```

Algorithm 3 Generierung stochastischer opaker Prädikate

```
1: Erstelle Funktion TransformiereVerteilung( $x$ ) im Modul, welche die gleichverteilte Variable  $x \in ]0; 1]$ 
...
2: procedure FÜGEPRÄDIKATEIN(Modul,  $T$ )
3:   for all Funktion in Modul do
4:     BasisBlock  $\leftarrow$  ZUFÄLLIGERBASISBLOCK(Funktion)
5:     Entry  $\leftarrow$  ZUFÄLLIGEANWEISUNG(BasisBlock)
6:     ZufaelligerWert  $\leftarrow$  ERSTELLEFUNKTIONSAUFRUF(Gleichverteilung,  $]0; 1]$ )
7:
8:     TransformierteVariable  $\leftarrow$  ERSTELLEFUNKTIONSAUFRUF(TransformiereVerteilung, ZufaelligerWert)
9:     ERSTELLEVERGLEICH(TransformierteVariable)
10:
11:    BBimmer_wahr  $\leftarrow$  SPLITBLOCK(BasisBlock, Entry)           ▷ Basisblöcke für Prädikatenfälle
generieren
12:    BBnie_wahr  $\leftarrow$  NEUERBLOCK(Funktion)
13:
14:    ERSTELLEBEDINGTEVERZWEIGUNG("TransformierteVariable  $\geq T$ ", BBimmer_wahr, BBnie_wahr)
15:
16:    Fülle Basisblock BBnie_wahr mit zufälligen Anweisungen.
17:  end for
18: end procedure
```

6 Implementierung

6.1 Entscheidungen

Zur Implementierung kamen drei Ansätze in Betracht: die Entwicklung eines Bin2Bin-Obfuscators⁴, die Implementierung in Form eines LLVM-Passes [7, 8]⁵ sowie die Quellcodemanipulation⁶. Es wurde eine Entscheidung für einen LLVM-Pass getroffen aufgrund folgender Vorteile:

Durch die Nutzung von LLVM profitiert man von Abstraktion. Anstatt manuell Assembler-Anweisungen hinzuzufügen, Relocations zu managen und Support für verschiedene Betriebssysteme und Prozessorarchitekturen manuell zu übernehmen, kann dies indirekt einer Gruppe kompetenter Experten übergeben werden, welche sich aktiv damit befassen. Auch wenn andere Methoden wie ein Bin2Bin-Obfuscator direktere Kontrolle bieten würden, ist es fraglich ob eine Person in relativ kurzer Zeit verschieden gleiche Funktionalitäten besser implementieren könnte.

Ähnliches gilt für die Effizienz kompilierter Programme: Durch die abstrakte Zwischensprache in

⁴Direkte Manipulation von Assembler-Anweisungen existierender Programme.

⁵Nutzung des LLVM-Projekts, um einen sog. *Compiler-Pass* zu schreiben.

⁶durch z.B. C-Makros und das Einfügen von inline Assembler-Ausschnitten

LLVM profitiert man von der konstanten Verbesserung tausender LLVM-Contributer, welche dafür sorgen, dass die eigenen Programme nahezu optimal kompiliert werden. Auch das ledigliche Einfügen vieler Prädikate an zufälligen Stellen kann in größeren Programmen bereits zu erhöhten Laufzeitkosten führen. In Situationen wie der Entwicklung für Embedded Systems, IoT und Echtzeitsystemen, können leicht erhöhte Laufzeiten gegen die Anwendung einer Obfuscation sprechen. Solchen Situationen begegnet man z.B. wie bei präziser optimierter medizinischer Technik sowie im Finanzwesen beim quantitativen Trading. In beiden Situationen kann eine leichte Verzögerung fatal sein - für Unternehmen und Personen.

Obfuscated Programme werden also effizienter und ihre Implementierung schneller, da sich auf die Obfuscation selbst fokussiert werden kann.

6.2 Generierung von Pseudozufallsvariablen

Damit der vorgestellte Ansatz funktionieren kann, bedarf er einer (Pseudo-)Zufallszahl, welche auf dem Einheitsintervall liegt und zugleich als unbestimmte symbolische Variable von symbolischen Ausführungsengines betrachtet wird. Hierfür werden die Parameter der obfuscated Funktionen verwendet. Die Idee hierhinter ist, dass um diese zu bestimmen, ... Hat die zu obfuscierende Funktion kein Parameter, so kann ein Pseudoparameter hinzugefügt werden. Um zu garantieren, dass die generierte Pseudozufallszahl im Einheitsintervall liegt, existieren mehrere Methoden. Es wurde sich für die einfachste entschieden. Hier wird der erste Parameter als 64-Bit Gleitkommazahl betrachtet und durch dessen maximalen Wert geteilt.

6.3 Wahrscheinlichkeitsverteilungsgenerierung

Um den Ansatz gegen *Pattern Matching* resistent zu machen, wird er generalisiert implementiert. Anstatt sich auf eine Wahrscheinlichkeitsdichtefunktion bzw. Umkehrfunktion der kumulativen Verteilungsfunktion zu beschränken, soll für jedes stochastisches opakes Prädikat eine neue Wahrscheinlichkeitsverteilung verwendet werden. Mehrere Methoden kommen hierfür infrage:

Generierung über Verteilungsklasse lorem ipsum dolor sit amet... Der Nachteil hiervon ist, dass ...

Generierung über zufälliges Polynom Eine Alternative ist die eigenständige Generierung einer zufälligen Funktion F , welche die Eigenschaften einer kumulativen Verteilungsfunktion (vgl. Definition 3.4) erfüllt. Das allgemeine Vorgehen hierfür ist Folgendes:

1. Wähle ein zufälliges Intervall $[a; b]$.
2. Teile $[a; b]$ in n Teile ein.
3. ...TODO

Die Nutzung eines einfachen Polynoms genügt hier nicht, da diese durch ihre häufigen Oszillationen kein notwendiges streng monotonen Steigen garantieren (vgl. Definition 3.4, Bedingung 1). Dies wird über Bernsteinpolynome gelöst:

$$B_n(x) = \sum_{k=0}^n c_k \binom{n}{k} x^k (1-x)^{n-k}.$$

6.4 Generierung von ununterscheidbarem Füllcode

Profuscation übernehmen [2]

7 Evaluierung

IDEE: Programmieren das geben und empirisch ermitteln!

7.1 Kriterien

Kriterien nach Collberg et al. evtl. auch was modernes zu KI...

7.2 Vergleich mit existierenden Obfuscationsmethoden

8 Ergebnisdiskussion

9 Fazit und Ausblick

Literaturverzeichnis

- [1] Roberto Baldoni u. a. *A Survey of Symbolic Execution Techniques*. Mai 2018. doi: [10.48550/arXiv.1610.00502](https://doi.org/10.48550/arXiv.1610.00502). eprint: [1610.00502](https://arxiv.org/abs/1610.00502) (cs). (Besucht am 27.07.2025).
- [2] Juan Caballero, Urko Zurutuza und Ricardo J. Rodríguez, Hrsg. *Detection of Intrusions and Malware, and Vulnerability Assessment: 13th International Conference, DIMVA 2016, San Sebastián, Spain, July 7-8, 2016, Proceedings*. Lecture Notes in Computer Science. Cham: Springer International Publishing, 2016. ISBN: 978-3-319-40666-4. doi: [10.1007/978-3-319-40667-1](https://doi.org/10.1007/978-3-319-40667-1). URL: <https://link.springer.com/10.1007/978-3-319-40667-1> (besucht am 20.07.2025).
- [3] Christian Collberg. *The Tigress C Obfuscator*. <https://tigress.wtf/>. 2025. (Besucht am 14.10.2025).
- [4] Christian Collberg, Clark Thomborson und Douglas Low. “A Taxonomy of Obfuscating Transformations”. In: <http://www.cs.auckland.ac.nz/staff-cgi-bin/mjd/csTRcgi.pl?serial> (Jan. 1997).
- [5] Christian Collberg, Clark Thomborson und Douglas Low. “Manufacturing Cheap, Resilient, and Stealthy Opaque Constructs”. In: *Proceedings of the 25th ACM SIGPLAN-SIGACT Symposium on Principles of Programming Languages - POPL '98*. The 25th ACM SIGPLAN-SIGACT Symposium. San Diego, California, United States: ACM Press, 1998, S. 184–196. doi: [10.1145/268946.268962](https://doi.org/10.1145/268946.268962). URL: <http://portal.acm.org/citation.cfm?doid=268946.268962> (besucht am 17.07.2025).
- [6] Pascal Junod u. a. “Obfuscator-LLVM – Software Protection for the Masses”. In: *Proceedings of the IEEE/ACM 1st International Workshop on Software Protection, SPRO'15, Firenze, Italy, May 19th, 2015*. Hrsg. von Brecht Wyseur. IEEE, 2015, S. 3–9. doi: [10.1109/SPRO.2015.10](https://doi.org/10.1109/SPRO.2015.10).
- [7] Chris Lattner und Vikram Adve. “LLVM: A Compilation Framework for Lifelong Program Analysis & Transformation”. In: *Proceedings of the International Symposium on Code Generation and Optimization (CGO)*. San Jose, CA, USA, 2004, S. 75–86. doi: [10.1109/CGO.2004.1281665](https://doi.org/10.1109/CGO.2004.1281665).
- [8] LLVM Project. *The LLVM Compiler Infrastructure*. <https://llvm.org/>. Version 20.1.4. 2003–2025. (Besucht am 18.08.2025).
- [9] Yan Shoshitaishvili u. a. “SoK: (State of) The Art of War: Offensive Techniques in Binary Analysis”. In: *IEEE Symposium on Security and Privacy*. 2016.
- [10] Ramtine Tofighi-Shirazi u. a. *Defeating Opaque Predicates Statically through Machine Learning and Binary Analysis*. 4. Sep. 2019. doi: [10.48550/arXiv.1909.01640](https://doi.org/10.48550/arXiv.1909.01640). arXiv: [1909.01640](https://arxiv.org/abs/1909.01640) [cs]. URL: [http://arxiv.org/abs/1909.01640](https://arxiv.org/abs/1909.01640) (besucht am 23.06.2025). Vorveröffentlichung.
- [11] Hui Xu u. a. “Manufacturing Resilient Bi-Opaque Predicates Against Symbolic Execution”. In: *2018 48th Annual IEEE/IFIP International Conference on Dependable Systems and Networks (DSN)*. 2018 48th Annual IEEE/IFIP International Conference on Dependable Systems and Networks (DSN). Luxembourg City: IEEE, Juni 2018, S. 666–677. doi: [10.1109/dsn.2018.00073](https://doi.org/10.1109/dsn.2018.00073). URL: <https://ieeexplore.ieee.org/document/8416525/> (besucht am 17.07.2025).

Abbildungsverzeichnis

1	Kontrollflussgraph einer einfachen Funktion mit opakem Prädikat. Abbildung aus der Disassembly des Spiels <i>Overwatch</i> mittels IDA entnommen.	2
2	Ausschnitt des Kontrollflussgraphen einer Funktion mit vielen opaken Prädikaten. Abbildung aus der Disassembly des Spiels <i>Overwatch</i> mittels IDA entnommen.	2
3	Opaque predicate examples attacking the challenges of symbolic execution.	4
4	Konzeptuelles Framework zur Erkennung opaker Prädikate mit symbolischer Ausführung, Abb. aus [11] übernommen	5